

Step1. 탐색 : 데이터의 기초 정보 살펴보기

Chipotle 데이터셋의 기본정보

In [1]:

```
#pandas 모듈 임포트
import pandas as pd

#read_csv() 함수로 데이터를 Dataframe 형태로 불러옵니다.
#pd.read_csv("파일 경로를 포함한 파일명", sep = "구분자")
#raw data를 상대 경로로 불러오기
file_path = '../data/chipotle.tsv'
chipo = pd.read_csv(file_path, sep="\t") #불러들인 파일의 정보를 chipo 변수에 담는다

chipo.shape #shape() 데이터의 행,열 크기 반환

print(chipo.info()) #info() 행, 열의 구성정보
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4622 entries, 0 to 4621
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  -
0  order_id              4622 non-null   int64
1  quantity              4622 non-null   int64
2  item_name             4622 non-null   object
3  choice_description    3376 non-null   object
4  item_price            4622 non-null   object
dtypes: int64(2), object(3)
memory usage: 180.7+ KB
None
```

In [2]:

```
#head() 데이터 프레임에서 위에서부터 10개의 데이터 보여주기
#tail() 밑에서 부터 데이터 보여주기
chipo.head(10)
chipo.tail()
```

Out[2]:

	order_id	quantity	item_name	choice_description	item_price
4617	1833	1	Steak Burrito	[Fresh Tomato Salsa, [Rice, Black Beans, Sour ...	\$11.75
4618	1833	1	Steak Burrito	[Fresh Tomato Salsa, [Rice, Sour Cream, Cheese...	\$11.75
4619	1834	1	Chicken Salad Bowl	[Fresh Tomato Salsa, [Fajita Vegetables, Pinto...	\$11.25
4620	1834	1	Chicken Salad Bowl	[Fresh Tomato Salsa, [Fajita Vegetables, Lettu...	\$8.75
4621	1834	1	Chicken Salad Bowl	[Fresh Tomato Salsa, [Fajita Vegetables, Pinto...	\$8.75

In [3]:

```
#columns()함수로 컬럼의 정보를 보여줌
chipo.columns
```

Out[3]:

```
Index(['order_id', 'quantity', 'item_name', 'choice_description',
      'item_price'],
      dtype='object')
```

In [4]:

```
#인덱스의 범위
chipo.index
```

Out[4]:

```
RangeIndex(start=0, stop=4622, step=1)
```

quantity 와 item_price의 요약 통계

describe() 수치형 요약통계

In [5]:

```
#describe() 함수로 요약통계량 출력하기 -> 수치형만!!
chipo.describe()
```

```
#count 수
#mean 평균
#std 표준편차
#min 최소값
#25% 사분의 일
#50% 사분의 이
```

Out[5]:

	order_id	quantity
count	4622.000000	4622.000000
mean	927.254868	1.075725
std	528.890796	0.410186
min	1.000000	1.000000
25%	477.250000	1.000000
50%	926.000000	1.000000
75%	1393.000000	1.000000
max	1834.000000	15.000000

In [6]:

```
#order_id는 숫자의 의미를 가지지 않기 때문에 문자타입(str)으로 변환
chipo['order_id'] = chipo['order_id'].astype(str)
chipo.describe()
```

Out[6]:

	quantity
count	4622.000000
mean	1.075725
std	0.410186
min	1.000000
25%	1.000000
50%	1.000000
75%	1.000000
max	15.000000

unique() 로 범주형 피처의 개수 출력하기

In [7]:

```
#order_id 개수 출력(중복되는 것 빼고 길이구함)
len(chipo['order_id'].unique()) #unique() 중복되는 것 빼고 고유한 범주
```

Out[7]:

1834

In [8]:

```
#item_name 개수 출력
len(chipo['item_name'].unique())
```

Out[8]:

50

Step2. 인사이트 발견: 탐색과 시각화

.value_counts()[:5] -> 가장 많이 주문한 것 순서대로, 시리즈 객체에만 적용!

In [9]:

```
#가장 많이 주문한 아이템 top10
chipo['item_name'].value_counts()[:10] #item_name 의 0번째부터 10번째까지 숫자형 value
```

Out[9]:

Chicken Bowl	726
Chicken Burrito	553
Chips and Guacamole	479
Steak Burrito	368
Canned Soft Drink	301
Steak Bowl	211
Chips	211
Bottled Water	162
Chicken Soft Tacos	115
Chips and Fresh Tomato Salsa	110

Name: item_name, dtype: int64

In [66]:

```

item_count = chipo['item_name'].value_counts()[:10]

#Top idx : 를 붙이기 위해 for문을 사용
for idx,(itemName,count) in enumerate(item_count.iteritems(),1): #iteritems() 열을 순
    print("Top", idx, ":", itemName, count)

```

```

Top 1 : Chicken Bowl 726
Top 2 : Chicken Burrito 553
Top 3 : Chips and Guacamole 479
Top 4 : Steak Burrito 368
Top 5 : Canned Soft Drink 301
Top 6 : Steak Bowl 211
Top 7 : Chips 211
Top 8 : Bottled Water 162
Top 9 : Chicken Soft Tacos 115
Top 10 : Chips and Fresh Tomato Salsa 110

```

item당 주문 개수와 총량 구하기 groupby()

In [11]:

```

#item 당 주문 개수를 출력합니다
#groupby() 함수는 데이터 프레임에서 특정 피처를 기준으로 그룹을 생성하여 이를 통해 그룹별
order_count = chipo.groupby('item_name')['order_id'].count() #item_name을 기준으로
order_count[:10]

```

Out[11]:

```

item_name
6 Pack Soft Drink    54
Barbacoa Bowl        66
Barbacoa Burrito     91
Barbacoa Crispy Tacos  11
Barbacoa Salad Bowl  10
Barbacoa Soft Tacos   25
Bottled Water        162
Bowl                  2
Burrito               6
Canned Soda          104
Name: order_id, dtype: int64

```

In [13]:

```
#아이템별 주문총량  
item_quantity = chipo.groupby('item_name')['quantity'].sum() #item_name을 기준으로  
item_quantity[:10]
```

Out[13]:

```
item_name  
6 Pack Soft Drink    55  
Barbacoa Bowl        66  
Barbacoa Burrito     91  
Barbacoa Crispy Tacos 12  
Barbacoa Salad Bowl  10  
Barbacoa Soft Tacos   25  
Bottled Water        211  
Bowl                  4  
Burrito               6  
Canned Soda          126  
Name: quantity, dtype: int64
```

시각화로 분석결과 살펴보기

In [14]:

```
%matplotlib inline  
import numpy as np  
import matplotlib.pyplot as plt
```

In [44]:

#아이템별 주문의 총량을 막대 그래프로 시각화
 #tolist()는 시리즈를 리스트로 변환하는 함수

item_name_list = item_quantity.index.tolist() #item_quantity 의 index를 tolist() 1차원

#numpy.arange(시작, 끝, 간격)으로 배열 만들기

x_pos = np.arange(len(item_name_list)) #x축: item_name의 리스트의 길이
 order_cnt = item_quantity.values.tolist() #item_quantity 의 value를 tolist() 1차원 리스트

#bar()는 막대 그래프를 출력해주는 함수 bar(x축, y축)


plt.bar(x_pos, order_cnt, align='center')

plt.ylabel('ordered_item_count') # y라벨

plt.xlabel('ordered_item') # x라벨

plt.title('Distribution of all ordered item') #제목

plt.show()



In [45]:

#아이템별 주문 개수 그래프

item_name_list = order_count.index.tolist() #item_quantity 의 index를 tolist() 1차원 리스트로

#numpy.arange(시작, 끝, 간격)으로 배열 만들기

x_pos = np.arange(len(item_name_list)) #item_name의 리스트의 길이

order_cnt2 = order_count.values.tolist() #order_count 의 value를 tolist() 1차원 리스트로

#bar()는 막대 그래프를 출력해주는 함수 bar(x축, y축)

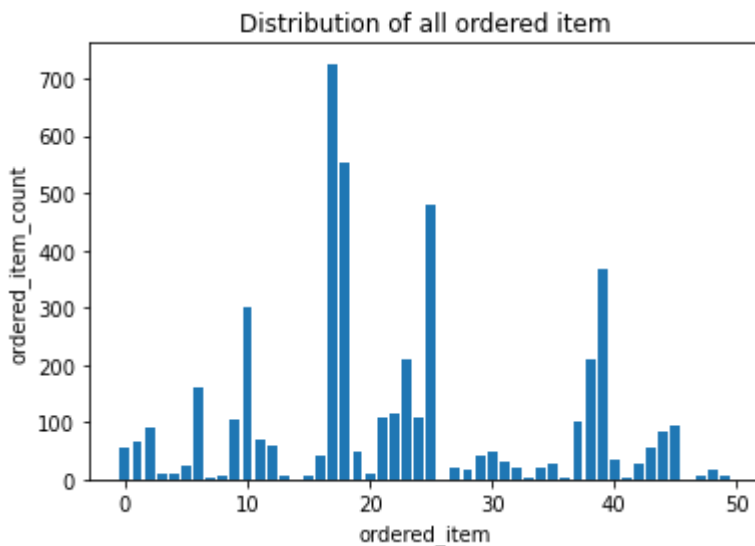
plt.bar(x_pos, order_cnt2, align='center')

plt.ylabel('ordered_item_count') # y라벨

plt.xlabel('ordered_item') # x라벨

plt.title('Distribution of all ordered item') #제목

plt.show()



In [59]:

산점도

item_name_list = order_count.index.tolist()


x_pos = np.arange(len(item_name_list))

order_cnt2 = order_count.values.tolist()

order_cnt = item_quantity.values.tolist()

```
plt.scatter(x_pos, order_cnt2, s=order_cnt2, label="ordered_item_count", c="red", m
plt.scatter(x_pos, order_cnt, s=order_cnt, label="total quantity of item", c="green",
plt.ylabel('ordered_item_count')
plt.xlabel('ordered_item')
plt.title('Distribution of all ordered item')
plt.legend(loc='upper left')
```

plt.show()



미니퀴즈 1-1

pandas에서 유용하게 사용되는 함수 value_counts()와 unique()의 차이

In [61]:

```
chipo['item_name'].value_counts()
```

Out[61]:

Chicken Bowl	726	
Chicken Burrito	553	
Chips and Guacamole	479	
Steak Burrito	368	
Canned Soft Drink	301	
Steak Bowl	211	
Chips	211	
Bottled Water	162	
Chicken Soft Tacos	115	
Chips and Fresh Tomato Salsa	110	
Chicken Salad Bowl	110	
Canned Soda	104	
Side of Chips	101	
Veggie Burrito	95	
Barbacoa Burrito	91	
Veggie Bowl	85	
Carnitas Bowl	68	
Barbacoa Bowl	66	
Carnitas Burrito	59	
Steak Soft Tacos	55	
6 Pack Soft Drink	54	
Chips and Tomatillo Red Chili Salsa	48	
Chicken Crispy Tacos	47	
Chips and Tomatillo Green Chili Salsa	43	
Carnitas Soft Tacos	40	
Steak Crispy Tacos	35	
Chips and Tomatillo-Green Chili Salsa	31	
Steak Salad Bowl	29	
Nantucket Nectar	27	
Barbacoa Soft Tacos	25	
Chips and Roasted Chili Corn Salsa	22	
Izze	20	
Chips and Tomatillo-Red Chili Salsa	20	
Veggie Salad Bowl	18	
Chips and Roasted Chili-Corn Salsa	18	
Barbacoa Crispy Tacos	11	
Barbacoa Salad Bowl	10	
Chicken Salad	9	
Veggie Soft Tacos	7	
Carnitas Crispy Tacos	7	
Veggie Salad	6	
Carnitas Salad Bowl	6	
Burrito	6	
Steak Salad	4	
Crispy Tacos	2	
Salad	2	
Bowl	2	
Chips and Mild Fresh Tomato Salsa	1	

Veggie Crispy Tacos 1
 Carnitas Salad 1
 Name: item_name, dtype: int64

In [62]:

```
type(chipo['item_name'].value_counts()) #value_counts() 시리즈
```

Out[62]:

pandas.core.series.Series

In [63]:

```
chipo['item_name'].unique()
```

Out[63]:

```
array(['Chips and Fresh Tomato Salsa', 'Izze', 'Nantucket Nectar',  

      'Chips and Tomatillo-Green Chili Salsa', 'Chicken Bowl',  

      'Side of Chips', 'Steak Burrito', 'Steak Soft Tacos',  

      'Chips and Guacamole', 'Chicken Crispy Tacos',  

      'Chicken Soft Tacos', 'Chicken Burrito', 'Canned Soda',  

      'Barbacoa Burrito', 'Carnitas Burrito', 'Carnitas Bowl',  

      'Bottled Water', 'Chips and Tomatillo Green Chili Salsa',  

      'Barbacoa Bowl', 'Chips', 'Chicken Salad Bowl', 'Steak Bowl',  

      'Barbacoa Soft Tacos', 'Veggie Burrito', 'Veggie Bowl',  

      'Steak Crispy Tacos', 'Chips and Tomatillo Red Chili Salsa',  

      'Barbacoa Crispy Tacos', 'Veggie Salad Bowl',  

      'Chips and Roasted Chili-Corn Salsa',  

      'Chips and Roasted Chili Corn Salsa', 'Carnitas Soft Tacos',  

      'Chicken Salad', 'Canned Soft Drink', 'Steak Salad Bowl',  

      '6 Pack Soft Drink', 'Chips and Tomatillo-Red Chili Salsa', 'Bow  

l',  

      'Burrito', 'Crispy Tacos', 'Carnitas Crispy Tacos', 'Steak Salad',  

      'Chips and Mild Fresh Tomato Salsa', 'Veggie Soft Tacos',  

      'Carnitas Salad Bowl', 'Barbacoa Salad Bowl', 'Salad',  

      'Veggie Crispy Tacos', 'Veggie Salad', 'Carnitas Salad'],  

      dtype=object)
```

In [64]:

```
type(chipo['item_name'].unique()) #unique() 배열
```

Out[64]:

numpy.ndarray

In [65]:

```
type(chipo['item_name'].unique().tolist()) #tolist() 1차원 배열로 만들어 줌
```

Out[65]:

list

In []: